INDUZIONE DI ALBERI DECISIONALI PER IL RICONOSCIMENTO DELLE MALATTIE CARDIOVASCOLARI

Nicola Sebastianelli

INTRODUZIONE

- Problema: Malattie cardiovascolari – una delle principali cause di mortalità a livello globale
- Obiettivo: Sviluppare un modello predittivo basato su alberi decisionali per identificare il rischio di malattie cardiovascolari
- Implementazione: Utilizzo del linguaggio Prolog per la costruzione e l'analisi dell'albero decisionale
- Confronto: Valutazione delle performance tra Coefficiente di Gini e Information Gain nella scelta degli attributi

SCELTA DEL DATABASE

- E’ stato utilizzato 'Cardio Database’
- Include 12 attributi clinici rilevanti per la diagnosi e la previsione del rischio.
- Dati reali su pazienti con e senza patologie cardiovascolari
- Scelto per l’ampia quantità di dati clinici

DESCRIZIONE DEL DATABASE

Attributi:

- Età, Sesso, Altezza, Peso
- Pressione Sistolica e Diastolica
- Colesterolo, Glucosio
- Fumo, Alcol, Attività fisica
- Variabile target: Presenza o assenza di malattia cardiovascolare

PREPARAZIONE DEI DATI

- Aggiunto dell'attributo BMI (Body Mass Index)
- Pulizia dei dati (gestione valori mancanti, anomalie)
- Suddivisione in training set (70%) e test set (30%)
- Bilanciamento delle classi

ALBERI DECISIONALI

- Modello predittivo basato su partizionamento ricorsivo
- Struttura ad albero facilmente interpretabile
- Ogni nodo rappresenta una variabile, mentre gli archi indicano i possibili valori
- Le foglie contengono la previsione finale sulla presenza o meno della malattia

ALGORITMO DI INDUZIONE DELL'ALBERO

- Selezione dell'attributo migliore
- Suddivisione dei dati in sottogruppi basati sull'attributo scelto
- Ripetizione del processo fino a soddisfare una condizione di stop
- Creazione dell'albero con nodi decisionali e foglie che indicano la classe finale

SCELTA DELL'ATTRIBUTO

- Coefficiente di Gini: misura l'impurità di un nodo

$$\sum_{i \neq j} P(i) \cdot P(j) = 1 - \sum_{classi} P\,(classe)^2$$

- Information Gain: basato sulla riduzione dell'entropia

$$\text{Gain(A)} = \text{B}\left(\frac{p}{p+n}\right) - \sum_{k=1}^{d} P(\text{T}S_k)\ \text{B}(\text{T}S_k)$$

CONFRONTO TRA GINI E GAIN INFORMATION

- Gini:
  - Pressione Sistolica → Colesterolo → Età → BMI → Glucosio → Alcol → Attività fisica → Pressione Diastolica → Sesso
- Information Gain:
  - Età → Alcol → BMI → Colesterolo → Pressione Diastolica → Sesso → Glucosio → Attività fisica → Fumo → Pressione Sistolica
- L'albero ricoprente ottenuto con Gini è più profondo, ma meno espanso
- Information Gain espande maggiormente l'albero

MATRICE DI CONFUSIONE E ACCURATEZZA

- Strumento essenziale per comprendere la qualità delle predizioni del modello.
- Rappresentazione dei veri positivi (VP), falsi positivi (FP), veri negativi (VN) e falsi negativi (FN)

Criterio	Test Effettuati	Non classificati	VP	FP	VN	FN	Accuratezza	Errore
Gini	20220	214	7061	1914	8111	2920	75.84%	24.16%
IG	20220	439	6971	1913	8031	2866	75.87%	24.13%

SFIDE, LIMITI E SVILUPPI FUTURI

- Bilanciamento e qualità dei dati: La presenza di casi clinici con stessi parametri e esiti diversi limita la capacità predittiva.
- Possibili miglioramenti futuri: Implementazione di Random Forest per ridurre l'overfitting e migliorare la generalizzazione.

CONCLUSIONI

- Gli alberi decisionali sono utili per la diagnosi.
- Il coefficiente di Gini e Information Gain hanno strutture diverse ma prestazioni simili.
- La variabilità clinica e la natura del dataset riducono l'accuratezza del modello.